



Simulação Quântica de Materiais para Baterias no Agreste Central:
Implementação do Algoritmo VQE com Machine Learning

Plano de Trabalho enviado à FACEPE
Editais FACEPE Nº 01/2025 – PIBIC/FACEPE

Aluno:

Yann Keven Jordão Leão – yann.kjleao@ufrpe.br
Unidade Acadêmica de Belo Jardim - UFRPE

Projeto de Pesquisa: Computação Quântica no Agreste Central: Simulação de Materiais
para Baterias com VQE e Machine Learning

Coordenador:

Fábio Magalhães de Novaes Santos – fabio.novaes@ufrpe.br
UABJ - UFRPE

13 de abril de 2025

1 Introdução

Este plano de trabalho integra o projeto de pesquisa de computação quântica aplicada a materiais para baterias, que tem como objetivo principal desenvolver simulações quânticas de materiais utilizando o algoritmo Variational Quantum Eigensolver (VQE). O VQE se destaca como uma técnica promissora para simulação de sistemas moleculares complexos, potencialmente superando diversas limitações dos métodos clássicos [1], com aplicações específicas no estudo de compostos fundamentais para baterias, como Li_2O e LiH [2, 3]. Neste contexto, o bolsista terá um papel central na implementação prática da pesquisa, utilizando ferramentas nacionais como Ket e QuBox para prototipagem inicial [4], antes da validação em plataformas internacionais consolidadas (Qiskit/ORCA) [5, 6].

As atividades do bolsista serão focadas na implementação do VQE para moléculas simples (H_2 , LiH , Li_2O), realizando simulações comparativas em múltiplas plataformas computacionais. Um aspecto importante do trabalho será a integração de técnicas de machine learning para otimização dos parâmetros do algoritmo [7, 8], buscando acelerar a convergência dos cálculos. Todo o processo será documentado em formatos abertos, garantindo a reprodutibilidade dos resultados.

A abordagem proposta combina três eixos principais: (1) o uso de ferramentas brasileiras (Ket/QuBox) para aprendizagem e prototipagem inicial, proporcionando um ambiente acessível para o desenvolvimento das primeiras competências em programação quântica; (2) a validação dos resultados em plataformas consolidadas internacionalmente (Qiskit/ORCA), assegurando o rigor científico dos achados; e (3) a integração sistemática com técnicas de machine learning, modernizando o fluxo de trabalho computacional. Esta estratégia não apenas garante a qualidade técnica da pesquisa, mas também proporciona ao bolsista uma formação abrangente, desenvolvendo habilidades práticas em programação científica e experiência em problemas reais de ciência de materiais, ao mesmo tempo que contribui para o avanço do conhecimento em uma área estratégica para o desenvolvimento tecnológico do país.

2 Objetivos Específicos

- a) Assimilar fundamentos de computação quântica e química quântica
- b) Dominar ferramentas (Ket, QuBox, Qiskit, ORCA)
- c) Implementar VQE para (H_2 , LiH , Li_2O)
- d) Validar resultados com métodos clássicos
- e) Testar em hardware quântico (IBM)
- f) Otimizar parâmetros com machine learning
- g) Produzir protocolos para transferência tecnológica (ITEMM)

3 Materiais e Métodos

O projeto será desenvolvido utilizando um conjunto integrado de ferramentas computacionais e uma abordagem metodológica estruturada em quatro fases principais. Para as simulações quânticas, utilizaremos a plataforma Ket [4] como ambiente principal de programação, complementada pelo simulador local QuBox para prototipagem e pelo IBM Qiskit para execução em hardware quântico real [9, 5]. As validações clássicas serão realizadas com o software ORCA [6], referência em química computacional, e com o pacote PySCF como alternativa para cálculos DFT [10].

A metodologia seguirá uma progressão trimestral de complexidade. No primeiro trimestre, o bolsista será capacitado através da página do curso de Computação Quântica do prof. Eduardo Duzzioni da UFSC [11], combinando fundamentos teóricos com exercícios práticos de implementação de circuitos quânticos básicos nos ambientes Ket e QuBox [4]. O segundo trimestre focará na implementação do algoritmo VQE, iniciando pela molécula de H_2 como sistema modelo, seguindo o tutorial disponível no repositório [12], que integra Qiskit com técnicas de otimização por gradiente descendente. Nesta fase, os resultados quânticos serão sistematicamente comparados com simulações clássicas no ORCA.

O terceiro trimestre será dedicado à aplicação avançada em sistemas relevantes para baterias, particularmente o óxido de lítio (Li_2O) [13], onde exploraremos a integração de técnicas de machine learning para otimização de parâmetros, utilizando bibliotecas como Scikit-learn [14] e TensorFlow [15]. Finalmente, no quarto trimestre, os circuitos otimizados serão executados na IBM Quantum Platform [5], com análise quantitativa de métricas de desempenho como fidelidade e sensibilidade ao ruído [8, 16].

Para mitigação de riscos, adotaremos três estratégias principais: (1) uso prioritário de simuladores locais (QuBox) para etapas iniciais, reduzindo a dependência de hardware quântico ruidoso; (2) implementação de múltiplos otimizadores (COBYLA, SPSA) para garantir convergência do VQE [7]; e (3) estabelecimento de parcerias acadêmicas alternativas para validação experimental, caso a colaboração com o ITEMm sofra atrasos. Todo o fluxo de trabalho será documentado em repositórios versionados, garantindo reprodutibilidade e facilitando a transferência tecnológica futura.

4 Resultados Esperados para a Vigência da Bolsa

Ao longo da execução do projeto, espera-se que o bolsista alcance os seguintes resultados, organizados por trimestre:

- **Primeiro Trimestre (Meses 1–3):**
 - Domínio dos fundamentos teóricos da computação quântica e química quântica.
 - Familiarização com as ferramentas de simulação quântica (Ket, QuBox, Qiskit).
 - Produção de um relatório teórico comparativo entre as plataformas Ket e Qiskit.
- **Segundo Trimestre (Meses 4–6):**
 - Implementação funcional do algoritmo VQE para moléculas simples (H_2 , LiH).
 - Validação dos resultados por comparação com simulações clássicas no software ORCA.
 - Publicação do código desenvolvido em repositório aberto no GitHub.
 - Preparação do relatório parcial de progresso.
- **Terceiro Trimestre (Meses 7–9):**
 - Simulação de moléculas complexas relevantes para baterias (Li_2O).
 - Integração de técnicas de aprendizado de máquina para otimização de parâmetros.
 - Criação de um dataset público contendo os resultados das simulações realizadas.
- **Quarto Trimestre (Meses 10–12):**
 - Execução de circuitos quânticos em hardware real da IBM Quantum Platform.
 - Análise de métricas de desempenho (fidelidade, ruído) em comparação com simuladores.
 - Consolidação dos resultados em relatório técnico final.
 - Apresentação dos resultados em evento científico da FACEPE.
 - Elaboração de protocolo para futura colaboração com o ITEMm.

5 Cronograma de Atividades

A Figura 1 ilustra a distribuição das atividades ao longo do período de execução do projeto:




Figura 1: Cronograma de execução das etapas do projeto.

Referências Bibliográficas

- [1] J. Tilly, H. Chen, S. Cao, D. Picozzi, K. Setia, Y. Li, E. Grant, L. Wossnig, I. Rungger, G. H. Booth, and J. Tennyson, "The Variational Quantum Eigensolver: A review of methods and best practices," *Physics Reports*, vol. 986, pp. 1–128, Nov. 2022.
- [2] J. E. Rice, T. P. Gujarati, M. Motta, T. Y. Takeshita, E. Lee, J. A. Latone, and J. M. Garcia, "Quantum computation of dominant products in lithium–sulfur batteries," *The Journal of Chemical Physics*, vol. 154, no. 13, p. 134115, Apr. 2021.
- [3] K. Kim, S. Lim, K. Shin, G. Lee, Y. Jung, W. Kyoung, J.-K. K. Rhee, and Y. M. Rhee, "Variational quantum eigensolver for closed-shell molecules with non-bosonic corrections," *Physical Chemistry Chemical Physics*, vol. 26, no. 10, pp. 8390–8396, 2024.
- [4] E. C. R. da Rosa and R. de Santiago, "Ket quantum programming," *J. Emerg. Technol. Comput. Syst.*, vol. 18, no. 1, oct 2021. [Online]. Available: <https://doi.org/10.1145/3474224>
- [5] A. Javadi-Abhari, M. Treinish, K. Krsulich, C. J. Wood, J. Lishman, J. Gacon, S. Martiel, P. D. Nation, L. S. Bishop, A. W. Cross *et al.*, "Quantum computing with qiskit," *arXiv preprint arXiv:2405.08810*, 2024.
- [6] F. Neese, "Software update: The orca program system—version 5.0," *Wiley Interdisciplinary Reviews: Computational Molecular Science*, vol. 12, no. 5, p. e1606, 2022.
- [7] X. Bonet-Monroig, H. Wang, D. Vermetten, B. Senjean, C. Moussa, T. Bäck, V. Dunjko, and T. E. O'Brien, "Performance comparison of optimization methods on variational quantum algorithms," *Physical Review A*, vol. 107, no. 3, p. 032407, Mar. 2023.
- [8] A. Karim, S. Zhang, and M. Usman, "Fast and Noise-aware Machine Learning Variational Quantum Eigensolver Optimiser," Mar. 2025.

- [9] "Getting started with Qiskit | IBM Quantum Learning." [Online]. Available: <https://learning.quantum.ibm.com/learning-path/getting-started-with-qiskit>
- [10] Q. Sun, T. C. Berkelbach, N. S. Blunt, G. H. Booth, S. Guo, Z. Li, J. Liu, J. D. McClain, E. R. Sayfutyarova, S. Sharma *et al.*, "Pyscf: the python-based simulations of chemistry framework," *Wiley Interdisciplinary Reviews: Computational Molecular Science*, vol. 8, no. 1, p. e1340, 2018.
- [11] E. Chagas Ribeiro da Rosa, "Curso de Computação Quântica da UFSC," <https://aprenda.quantumket.org/>, 2024, acesso em: 11/04/2025.
- [12] J. Saslow, "VQE Tutorial – H₂ Molecule," <https://github.com/jamessaslow/VQE-Tutorial-H2>, Oct. 2023, acesso em: 11/04/2025.
- [13] H. C. Choi, Y. M. Jung, I. Noda, and S. B. Kim, "A Study of the Mechanism of the Electrochemical Reaction of Lithium with CoO by Two-Dimensional Soft X-ray Absorption Spectroscopy (2D XAS), 2D Raman, and 2D Heterospectral XAS-Raman Correlation Analysis," *The Journal of Physical Chemistry B*, vol. 107, no. 24, pp. 5806–5811, Jun. 2003.
- [14] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, M. Blondel, P. Prettenhofer, R. Weiss, V. Dubourg *et al.*, "Scikit-learn: Machine learning in python," *the Journal of machine Learning research*, vol. 12, pp. 2825–2830, 2011.
- [15] M. Abadi, P. Barham, J. Chen, Z. Chen, A. Davis, J. Dean, M. Devin, S. Ghemawat, G. Irving, M. Isard *et al.*, "TensorFlow: a system for Large-Scale machine learning," in *12th USENIX symposium on operating systems design and implementation (OSDI 16)*, 2016, pp. 265–283.
- [16] F. Noé, A. Tkatchenko, K.-R. Müller, and C. Clementi, "Machine Learning for Molecular Simulation," *Annual Review of Physical Chemistry*, vol. 71, no. Volume 71, 2020, pp. 361–390, Apr. 2020.